

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

Curso de Machine Learning

**DIABETESAI: CLASSIFICAÇÃO DE RISCO DE DIABETES
COM MACHINE LEARNING**

Relatório do Trabalho Final

Leonardo Soares Castro

Belo Horizonte

2026

SUMÁRIO

1 INTRODUÇÃO	2
2 O CONJUNTO DE DADOS	3
3 METODOLOGIA.....	3
4 RESULTADOS	4
5 INTERFACE GRÁFICA.....	8
6 CONCLUSÃO.....	10
REFERÊNCIAS	11

1 INTRODUÇÃO

O presente trabalho foi desenvolvido como projeto final da disciplina **Machine Learning**, na **Pontifícia Universidade Católica de Minas Gerais (PUC Minas)**. Tomando como inspiração o projeto **DiabetesAI**, que combina um modelo de classificação com uma API e uma interface web, este trabalho propõe uma solução construída do zero para estimar o risco de diabetes em pacientes a partir de indicadores clínicos de rotina.

O **diabetes mellitus** é uma das doenças crônicas mais prevalentes no mundo, e seu diagnóstico tardio está associado a complicações graves, como doenças cardiovasculares, insuficiência renal e neuropatias. Ferramentas de triagem baseadas em dados clínicos simples e de baixo custo podem auxiliar profissionais de saúde a identificar precocemente indivíduos com maior risco, reforçando a importância de investigações complementares. Nesse contexto, técnicas de aprendizado de máquina se mostram adequadas por conseguirem capturar relações não triviais entre múltiplos indicadores clínicos e o desfecho da doença.

O objetivo geral deste trabalho é percorrer o ciclo completo de um projeto de ciência de dados: da exploração e do pré-processamento dos dados à comparação de diferentes algoritmos de classificação, culminando na disponibilização do melhor modelo por meio de uma API e de uma interface gráfica web. Especificamente, buscou-se: (i) treinar e comparar quatro algoritmos de classificação supervisionada; (ii) avaliar os modelos por métricas de desempenho amplamente aceitas na literatura; (iii) interpretar as predições do melhor modelo; e (iv) construir uma aplicação web funcional capaz de consumir esse modelo em tempo real.

2 O CONJUNTO DE DADOS

Foi utilizado o conjunto de dados *Pima Indians Diabetes Database*, disponibilizado publicamente pelo *UCI Machine Learning Repository* e amplamente utilizado em trabalhos de classificação binária na área da saúde. O conjunto contém 768 registros de pacientes do sexo feminino, descritos por 8 variáveis preditoras e uma variável-alvo binária (*Outcome*), indicando a presença (1) ou a ausência (0) de diabetes.

Tabela 1 – Descrição das variáveis do conjunto de dados

Variável	Descrição
Pregnancies	Número de gestações
Glucose	Concentração de glicose no plasma
BloodPressure	Pressão sanguínea diastólica (mm Hg)
SkinThickness	Espessura da dobra cutânea do tríceps (mm)
Insulin	Insulina sérica em 2 horas ($\mu\text{U/mL}$)
BMI	Índice de massa corporal
DiabetesPedigreeFunction	Função de histórico familiar de diabetes
Age	Idade (anos)
Outcome	1 = diabético, 0 = não diabético (variável-alvo)

Fonte: elaborado pelo autor.

Uma inspeção inicial revelou que o conjunto de dados não possui valores nulos (NaN); entretanto, cinco colunas apresentam o valor zero em situações clinicamente impossíveis — por exemplo, pressão sanguínea ou glicose iguais a zero —, o que indica dados ausentes codificados como zero. A Tabela 2 resume a ocorrência desses valores. Não foram identificadas linhas duplicadas no conjunto de dados.

Tabela 2 – Ocorrência de zeros clinicamente inválidos

Coluna	Zeros	Percentual
Glucose	5	0,7%
BloodPressure	35	4,6%
SkinThickness	227	29,6%
Insulin	374	48,7%
BMI	11	1,4%

Fonte: elaborado pelo autor.

3 METODOLOGIA

Os valores zero identificados nas colunas *Glucose*, *BloodPressure*, *SkinThickness*, *Insulin* e *BMI* foram substituídos pela mediana da respectiva coluna, por ser menos sensível a valores extremos do que a média. Em seguida, o conjunto de dados foi dividido em 70% para

treino e 30% para teste, com estratificação pela variável-alvo, de modo a preservar a proporção original das classes (aproximadamente 65% não diabético e 35% diabético). Por fim, todas as variáveis preditoras foram padronizadas com o *StandardScaler* da biblioteca *scikit-learn* — etapa necessária ao bom funcionamento da Regressão Logística e inócua para os modelos baseados em árvores.

Foram treinados e comparados quatro algoritmos de classificação supervisionada, escolhidos por representarem abordagens distintas: Regressão Logística (modelo linear), Árvore de Decisão (modelo baseado em regras), *Random Forest* e *XGBoost* (ambos ensembles de árvores, respectivamente por bagging e por boosting). Todos os modelos foram treinados com semente aleatória fixa (*random_state = 42*), garantindo a reprodutibilidade dos resultados.

O desempenho dos modelos foi avaliado no conjunto de teste por meio de cinco métricas: Acurácia, Precisão, Recall, F1-Score e Área sob a Curva ROC (AUC-ROC). Em razão do desbalanceamento das classes, a AUC-ROC foi adotada como critério principal para a escolha do melhor modelo, por ser menos sensível a esse desbalanceamento do que a acurácia.

4 RESULTADOS

A Tabela 3 apresenta a comparação de desempenho dos quatro modelos no conjunto de teste.

Tabela 3 – Comparação de desempenho dos modelos

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Regressão Logística	0,7446	0,6719	0,5309	0,5931	0,8361
Random Forest	0,7359	0,6562	0,5185	0,5793	0,8230
XGBoost	0,7446	0,6528	0,5802	0,6144	0,8172
Árvore de Decisão	0,7316	0,6338	0,5556	0,5921	0,7488

Fonte: elaborado pelo autor.

A Regressão Logística obteve o melhor desempenho pelo critério AUC-ROC (0,8361), superando inclusive os modelos de ensemble, o que sugere que as relações entre as variáveis preditoras e o desfecho são majoritariamente lineares neste conjunto de dados. As Figuras 1 a 5 ilustram, respectivamente, a distribuição da variável-alvo, a matriz de correlação entre as variáveis, a comparação gráfica das métricas dos quatro modelos, a curva ROC comparativa e as matrizes de confusão de cada modelo.




Figura 1 – Distribuição da variável alvo (Outcome)

Fonte: elaborado pelo autor.




Figura 2 – Matriz de correlação entre as variáveis
 Fonte: elaborado pelo autor.




Figura 3 – Comparação das métricas dos quatro modelos
 Fonte: elaborado pelo autor.




Figura 4 – Curva ROC comparativa dos quatro modelos

Fonte: elaborado pelo autor.




Figura 5 – Matrizes de confusão dos quatro modelos


Fonte: elaborado pelo autor.

A análise de interpretabilidade com SHAP e LIME, realizada no notebook do experimento, indicou que Glucose, BMI, Age e DiabetesPedigreeFunction estão entre as variáveis mais influentes nas previsões do modelo, resultado coerente com o conhecimento clínico sobre fatores de risco para diabetes tipo 2.

5 INTERFACE GRÁFICA

O melhor modelo, juntamente com o normalizador (StandardScaler) e a lista ordenada de variáveis, foi exportado com a biblioteca joblib e passou a ser consumido por uma API construída com o framework FastAPI, que expõe o endpoint POST /predict. Essa API é consumida por uma interface web construída em React, que permite ao usuário informar os 8 indicadores clínicos do paciente e visualizar o resultado da predição.

O uso da aplicação consiste em preencher os 8 campos numéricos do formulário (Figura 6) com os dados do paciente e clicar no botão "Verificar risco de diabetes". Em caso de sucesso, a interface exibe um selo de risco (baixo, moderado ou alto), a classificação prevista (diabético ou não diabético) e a probabilidade estimada pelo modelo (Figura 7). Caso algum valor informado seja inválido — como um valor de glicose negativo —, a API rejeita a requisição e a interface exibe uma mensagem de erro amigável, identificando o campo e o motivo da rejeição (Figura 8).



DiabetesAI

Estimativa de risco de diabetes a partir de indicadores clínicos, usando um modelo de Regressão Logística treinado no dataset Pima Indians Diabetes.

Ferramenta educacional — não substitui diagnóstico médico.

Gestações	Glicose (mg/dL)
1	117
Pressão sanguínea (diastólica) (mmHg)	Espessura da pele (triceps) (mm)
72	23
Insulina sérica (2h) (µU/mL)	IMC (kg/m ²)
30	32
Histórico familiar (índice)	Idade (anos)
0,3725	29

Verificar risco de diabetes

Preencha os dados e clique em "Verificar risco de diabetes" para ver o resultado aqui.

Figura 6 – Tela principal da aplicação DiabetesAI
Fonte: elaborado pelo autor.

DiabetesAI

Estimativa de risco de diabetes a partir de indicadores clínicos, usando um modelo de Regressão Logística treinado no dataset Pima Indians Diabetes.

Ferramenta educacional — não substitui diagnóstico médico.

Gestações

6

Pressão sanguínea (diastólica) (mmHg)

72

Insulina sérica (2h) (µU/mL)

30

Histórico familiar (índice)

0,3725

Glicose (mg/dL)

190

Espessura da pele (tríceps) (mm)

23

IMC (kg/m²)

42

Idade (anos)

55

Verificar risco de diabetes

Risco alto

Diabético

Probabilidade estimada: 96.3%

Figura 7 – Resultado de uma predição de alto risco (caso de sucesso)
Fonte: elaborado pelo autor.

DiabetesAI

Estimativa de risco de diabetes a partir de indicadores clínicos, usando um modelo de Regressão Logística treinado no dataset Pima Indians Diabetes.

Ferramenta educacional — não substitui diagnóstico médico.

Gestações

1

Pressão sanguínea (diastólica) (mmHg)

72

Insulina sérica (2h) (µU/mL)

30

Histórico familiar (índice)

0,3725

Glicose (mg/dL)

-10

Espessura da pele (tríceps) (mm)

23

IMC (kg/m²)

32

Idade (anos)

29

Verificar risco de diabetes

Não foi possível calcular o resultado.

Glicose: valor inválido (Input should be greater than or equal to 0).

Figura 8 – Tratamento de erro para uma entrada inválida (caso negativo)
Fonte: elaborado pelo autor.

6 CONCLUSÃO

Este trabalho percorreu o ciclo completo de um projeto de classificação supervisionada, da exploração dos dados à disponibilização do modelo em uma aplicação web. Na etapa de pré-processamento, optou-se por substituir os zeros clinicamente inválidos pela mediana de cada coluna, já que tratá-los como valores reais distorceria a análise — a coluna Insulin, por exemplo, apresentava 48,7% de zeros. Também foram padronizadas todas as variáveis com StandardScaler, o que permitiu usar o mesmo pipeline de inferência para os quatro modelos avaliados.

Entre os quatro algoritmos comparados, a Regressão Logística obteve o melhor resultado pelo critério AUC-ROC (0,8361), seguida por Random Forest (0,8230), XGBoost (0,8172) e Árvore de Decisão (0,7488). O fato de um modelo linear e interpretável ter superado os ensembles mais complexos reforça que, neste conjunto de dados relativamente pequeno, a relação entre os indicadores clínicos e o risco de diabetes é majoritariamente linear.

Do ponto de vista do problema de negócio, a aplicação desenvolvida cumpre o papel de uma ferramenta de triagem preventiva: a partir de indicadores clínicos de rotina, é possível estimar rapidamente o risco de um paciente ser diabético, auxiliando profissionais de saúde a priorizar exames complementares e conduta clínica. É importante ressaltar, contudo, que a ferramenta tem caráter educacional e não substitui o diagnóstico médico, devendo seu resultado ser sempre interpretado em conjunto com avaliação profissional.

Como limitações, destacam-se o tamanho reduzido e o desbalanceamento do conjunto de dados, o que penaliza o Recall de todos os modelos testados, e a simplicidade da imputação por mediana. Como melhorias futuras, sugerem-se: o uso de técnicas de imputação mais sofisticadas (KNNImputer, MICE); a otimização de hiperparâmetros com GridSearch ou Optuna; a ampliação da base de dados; e a implantação da aplicação em um ambiente de produção, com monitoramento contínuo da qualidade das previsões ao longo do tempo.

REFERÊNCIAS

UCI MACHINE LEARNING REPOSITORY. Pima Indians Diabetes Database. Disponível em: <https://archive.ics.uci.edu/dataset/34/diabetes>. Acesso em: 18 jul. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Disponível em: <https://scikit-learn.org/>. Acesso em: 18 jul. 2026.

XGBOOST DEVELOPERS. XGBoost Documentation. Disponível em: <https://xgboost.readthedocs.io/>. Acesso em: 18 jul. 2026.

LUNDBERG, S. SHAP (SHapley Additive exPlanations) Documentation. Disponível em: <https://shap.readthedocs.io/>. Acesso em: 18 jul. 2026.

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. LIME (Local Interpretable Model-agnostic Explanations). Disponível em: <https://github.com/marcotcr/lime>. Acesso em: 18 jul. 2026.

FASTAPI. FastAPI Framework Documentation. Disponível em: <https://fastapi.tiangolo.com/>. Acesso em: 18 jul. 2026.

REACT. React – A JavaScript Library for Building User Interfaces. Disponível em: <https://react.dev/>. Acesso em: 18 jul. 2026.